第十三章 人类、AI 与机器人：在未来边界上继续学习

开篇：最后一个确认按钮

一家医院的物流部门想把夜班中的一段搬运和分拣交给能够移动、识别物品并操作设备的机器人。系统根据库存、路线和安全规则安排了下一步，还把一项不可逆的处置标成“建议确认”。夜班员工同时处理几件急事，没有时间看完全部记录，也没有权限暂停系统，只能在屏幕上按下确认。

这个场景不是对未来的预言，而是一个用来追问边界的思想实验。机器人也许更快、更稳定，也许能够把人的体力从危险和重复劳动中解放出来；但它仍没有自动回答：谁有权让它行动？谁能在异常时停下来？谁承担不可逆的后果？那名按下按钮的人究竟作出了判断，还是只为一条已经形成的控制链留下了姓名？

本章是全书的开放性结尾。它不宣布技术终局，不判断超级智能是否必然出现，也不把人类必然从执行者变成目标设定者。我们只沿着一条条件式路径前进：先分清机器能做什么与谁有权让它做，再拆开执行、目标、监督和意义四个角色，检查身体经验、社会关系和价值判断的边界，最后用不同制度下的替代情景，回到“人为什么仍然需要学习”这个问题。

一、先分清“能做什么”与“谁有权做什么”

现实中的人机团队并不是一种固定模式。不同任务、领域、团队结构和风险条件，会改变人和系统各自承担的工作。已有讨论把人机协作放在多种应用和高风险场景中考察，但相关材料的研究设计、适用范围和具体结论仍需要分别核对。因此，更精确的问题不是“机器人会不会取代人类”，而是：

- 系统看到了什么，又遗漏了什么？
- 谁提出了计划，谁改变了目标？
- 机器人执行到哪一步，哪一步必须停下来？
- 谁拥有修改、暂停、拒绝和恢复的权限？
- 谁向受影响的人解释，谁承担并修复不可逆的后果？

把行动权限拆开，有助于避免把能力误读成授权。一个系统可以观察环境，却不能自行改变现实；可以提出路径，却需要人或共同体确认目标；可以在低风险、可逆的范围内执行，却必须在红线出现时暂停；可以优化局部任务，却不因此获得替他人作出价值承诺的权力。

自治也不只是“开”或“关”。关于人机团队的讨论把自治看作可以调节的协作变量，这提示我们关注接管条件、反馈、权限和可逆性。不过，这种设计思路不等于具体系统已经安全，也不等于责任会随着自动化程度提高而自动转移。系统越能自己完成步骤，越需要问清楚授权从哪里来、谁能够改变它、出了问题谁能够修复。

二、用四个问题拆开四种角色

1. 执行者：不亲手做，不等于不需要懂

如果机器人能够在物理环境中稳定感知、移动并完成一部分任务，那么人的学习可能部分转向任务分解、环境建模、异常识别、边界设定和恢复策略。人可以不再记住每个操作步骤，却仍需知道约束在哪里、什么情况属于异常，以及何时不应继续让系统行动。

这不是说执行者角色必然消失。在某些学习或专业任务中，亲自执行可能仍有助于理解因果、形成身体直觉和发现隐性条件；在另一些高危场景中，减少人的直接暴露可能是合理安排。结论取决于学习目标、错误代价和能否获得真实反馈。关于 AI 辅助批判性思维的讨论也只提醒我们：完成任务的表现，不必然等于人的批判性思维能力已经形成。

2. 目标设定者：建议生成不等于目的成立

如果系统能够根据大量数据提出课程路径、工作目标或资源配置建议，那么建议生成者与目标设定者可能分离。系统或许能列出候选目标、显示冲突、模拟后果；但“什么值得追求、谁承担代价、哪些东西不能交换”仍然需要公共理由和价值判断。

系统说“把吞吐量最大化就是最优方案”，并不等于共同体同意牺牲谁的休息、尊严或安全来换取速度。目标不能从能力中自动推出，责任也不能从一次点击中自动推出。学习者需要识别目标的来源、指标遗漏、代理目标和受影响者，而不只是把目的翻译成机器能够优化的形式。

这不证明目标设定在任何情况下都必须由人独占。未来如果系统参与目标讨论，仍要回答它从谁那里获得授权、能否被质询、代表谁、如何回应异议，以及后果发生后由谁负责。这些是制度问题，不是由输出质量单独决定的问题。

3. 监督者：签字不等于有意义监督

如果系统的行动速度、复杂度或数量超过单个操作者的即时理解能力，监督可能需要从逐步批准转向权限分层、记录、抽样检查、红线规则、接管机制、独立复核和群体治理。

想象那名夜班员工按下确认：他没有时间读完日志，不知道系统为何改变路线，也没有暂停权限。即使页面上完整记录了“由人确认”，这也不自动构成有意义的监督。监督至少需要必要的信息、理解和质询能力、形成判断的时间、暂停或覆盖权限，以及结果出现后的复盘和修复资源。

关于高风险 AI 使用的讨论把监督放在技术、安全与规范条件的交叉处，并特别提醒形式上的“人在回路中”可能不足以形成真实控制。这一提醒不能直接证明某种制度设计必然有效，也不能把医疗等高风险场景的线索原样推广到教育、家庭或普通办公工具。它真正要求我们检查的是：被指定负责的人，是否真的能够改变行动方向。

4. 意义创造者：效率之外仍有“为什么”

如果 AI 与机器人承担越来越多可重复或可计算的工作，一部分人的生活可能转向学习、照护、创造、关系维护或公共参与；另一部分人也可能失去收入、身份、同伴关系和成就感。两种结果都不是自动化程度本身能够决定的，它们取决于所有权、分配、工作制度、教育安排和共同体价值。

意义不是效率的剩余项，也不是机器生成故事的同义词。一个行动是否有意义，可能与承诺谁、照护谁、经历什么困难、如何面对失败，以及愿意为哪些后果负责有关。机器人可以参与共同活动，也可以被设计成社会互动对象；但社会技能表现或互动频率不等于互惠关系、责任主体资格或共同价值。

机器是否可能拥有人的意义体验，仍是未知。此处应保留问题，而不是用拟人化表现提前给出答案。

三、三条不能由能力自动替代的边界

1. 身体经验：有传感器不等于有人的处境

关于视觉线索的人机协作讨论提示，空间位置、可观察动作和共同操作会进入协作设计。具身 AI 与教育的讨论也把认知、在场和学习生态联系起来。但这些材料不足以证明机器人拥有人的身体经验，也不足以证明具身系统必然改善学习。

人的身体经验还包括疲劳、疼痛、脆弱性、风险暴露、照护、被注视以及处于某种社会位置。机器人可能扩大人的感知和行动范围，也可能代替某些危险、重复或精细操作；这种扩展是否保留了学习所需的理解，取决于任务目的。若目标是掌握控制原理，自动化执行可能留下解释和调试任务；若目标是形成照护判断、风险感受或协作信任，把身体接触全部外包出去可能改变学习对象本身。

因此，“身体经验是否能够被技术扩展、部分替代或重新组织”是规范判断与待验证问题，不是“绝对不可技术化”的事实断言。

2. 社会关系：互动不自动成为关系

机器人可以被设计为提醒者、教练、照护辅助者或协作伙伴。它可能帮助降低孤立、扩展沟通渠道，也可能制造新的依赖和误解。一个机器人能记住你的偏好，在你低落时说出安慰的话，但你仍需要追问：它是否能够承诺？你能否退出？出了问题谁负责？它是否模拟了超出实际能力的关心？受影响者能否申诉并获得替代方案？

关于工作者对未来机器人的期待，已有摘要提示人们可能接受基本社会技能，却未必接受过高自治。这只能支持一个谨慎的入口：自治受到关系期待和场景规范约束，不能被外推为跨文化普遍规律，更不能把被设计成互动对象等同于拥有互惠关系或责任主体资格。

学习社会关系，不只是识别表情或生成礼貌回应，还包括理解互惠、脆弱性、权力、承诺和修复。机器人可以成为练习和支持关系能力的媒介，但拟人化表现本身不能证明关系已经成立。

3. 价值判断：扩展选项不等于替人正当化

技术能力回答“可以做什么”，制度与价值判断还要回答“谁有权做、为何这样做、谁承担代价、谁可以拒绝”。系统能够预测更多后果，可能让冲突更清楚，也可能把争议伪装成一个可优化的分数。价值判断不是拒绝数据，而是要求数据、模型和受影响者的理由共同进入审议。

这条边界也不意味着人类天然垄断价值推理。未来若系统参与价值讨论，仍需要可追问的理由、真实的代表关系、可修订的授权、对异议的回应，以及后果发生后的责任机制。“系统给出了价值排序”与“共同体接受了价值排序”不是同一件事。

四、两条替代情景：同样能力，不同制度结果

为了避免把未来写成单线叙事，把同一种技术能力放进两种制度中比较。以下是条件式思想实验，不是预测。

情景 A：能力增长，但制度保留人的实质参与

如果机器人在低风险、可逆任务中变得更可靠，那么组织可能允许更高程度的自动执行，同时把人的学习重点放在问题形成、目标审议、异常处理、跨领域解释和后果复盘。系统提供候选方案和行动能力，人和共同体保留授权、拒绝、修订与申诉空间。

在这个情景里，人的角色可能改变，但改变来自权限、记录、培训、退出和共同决策等制度安排，而不是来自能力提升本身。人仍需要学习，因为只有理解情境、质询目标和检查后果，参与才不会退化为形式。

情景 B：能力相近，但制度把人压缩为形式监督

如果组织只追求速度和成本，把系统输出当作默认答案，并把没有信息和权限的操作者安排在最后确认位置，那么即使系统能力没有发生戏剧性变化，人也可能失去问题形成、判断和修复能力。教育可能从理解变成提交无错结果，工作可能从共同决策变成指标服从，责任则在开发者、组织和操作者之间扩散。

这两条情景说明：技术能力不是制度结果的充分条件。相同的感知、规划和执行能力，可能服务于能力增强，也可能服务于责任外包。自治不自动转移责任，自动化程度也不自动赋予系统主体资格。

五、把“超级智能”当作治理压力测试

如果未来出现远超当前系统能力的 AI，并且它能提出人类难以直接评估的策略，那么人类可能需要更重视目标治理、独立复核、权限隔离、集体决策和不可逆行动的暂停机制。这只是一个治理压力测试：它帮助我们检查制度是否能在理解不完整时保留退出、申诉和修复路径。

现有材料只能说明，确实存在面向假设性未来的超级智能治理讨论；它们不能证明超级智能已经存在、必然出现、拥有时间表或会走向某个预定终局。关于全球灾难风险的术语背景也不能提供现实风险的概率、机制或治理效果。

在这个思想实验中，“人类是否还能理解一切”不是唯一问题。还要问：哪些行动必须暂停？哪些权限不能由单个组织持有？什么样的理由足以授权行动？受影响者如何参与？当知识不完整时，谁保留拒绝和修复的能力？未知越大，越不能用流畅叙事填补。

六、反例：未来边界也可能失败

第一，人类保留决策权也可能导致更差结果。疲劳、偏见、利益冲突或对系统的盲目信任，都可能使“人最后说了算”失去保障意义。反过来，系统在某些任务上可能更稳定，也不能直接推出它应获得所有目标、价值和承诺权。

第二，机器人有身体不等于拥有人类处境。空间线索和共同操作是协作变量，却不能证明意识、脆弱性、社会身份或意义体验。

第三，自动化可能减少负担，也可能减少意义。结果取决于工作如何分配、收益如何分享、学习与照护如何组织，以及人是否仍能参与有价值的共同活动。

第四，当前材料不能支撑未来因果结论。工作场景不能直接泛化到教育、家庭、医疗或公共治理；期待调查不能自动证明责任授权；概念讨论不能自动证明效果。

第五，未知不能被改写成两种极端。“机器最终会取代一切”和“人类价值永远不可技术化”都是未经支持的终局叙事。机器人是否拥有意识、主体性、价值判断或意义创造能力，未来系统的能力增长速度、物理可靠性、制度适配和分配后果，仍需分别追问。

七、回到全书：不亲手执行，如何仍然真正学习

前面各章逐步区分了有价值的知识、陌生领域的进入、知识内化、理解验证、迁移应用、人机协作、机器生成内容的验证、跨学科连接，以及主体性与责任。本章不为这条链条规定唯一终点，而是把它收束成一条面对不确定性的能力线：

1. **理解情境**：知道系统观察了什么、遗漏了什么，现实环境有哪些隐性约束。
2. **质询目标**：区分真正目的与代理指标，识别谁受益、谁承担代价。
3. **验证与迁移**：重建关键机制，寻找反例，在新情境中检验，而不只接受流畅结果。
4. **保留行动能力**：知道何时调用、何时接管、何时拒绝，避免把判断全部外包。
5. **参与共同创造**：在跨学科、跨代际和人机协作中解释差异，提出新问题和新可能。
6. **承担责任**：把权限、理由、后果、关系承诺和修复路径连接起来。

这不是“人类永远不可替代”的证明，也不是对未来职业的预测。它是一组教育与制度问题：即使机器承担更多执行，人仍需决定哪些经验值得保留、哪些风险可以委托、哪些关系不能被指标抹平，以及什么样的共同生活值得建设。

小结：把本章带走

回到开头那个场景：机器人接手了原本由人逐步完成的任务，最后仍由一名工作很满、信息不全的人为一次不可逆的处置按下确认。技术改变了谁能动手，却没有自动回答谁有权决定、谁有能力停下、谁承担后果、这件事对谁有意义。

如果只记住一件事，那就是：**能做什么、谁有权做、值不值得做，是三件必须分开讨论的事；同样可靠的机器，放进不同制度里，可能让人更有能力，也可能把人变成形式上的监督者。**

现在可以试一个小练习：挑一件你最近交给 AI 或自动化系统做的事，写下三句话——它被允许做到哪一步；如果出错谁能停下来；如果没有人能停下来，那一步需要什么权限、记录或申诉路径来补上。

这本书从一开始就在问：机器越来越能干之后，人为什么仍然需要学习。走到这里，一个可能的回答是：学习未必是亲手做完每一步，而是仍然能在工具、代理和机器存在时，看清情境，质询目标，验证结果，保留行动能力，参与共同创造，并为后果负责。这不是已经确定的结局，而是仍由我们共同选择的方向。

参考文献

- *From testbeds to high-stakes work: a review of Human-AI teaming domains and teaming factors*：用于说明人机协作需要按任务、领域、团队结构与风险描述，不把协作写成单一模式。来

源链接

- *Human–Robot Collaboration Using Visual Cues for Communication*：用于说明空间位置、可观察动作与共同操作会进入协作设计，不据此断言机器人拥有人的身体经验。来源链接
- *Workers expect basic social skills but limited autonomy from future robots*：用于说明社会技能期待与自治授权不能混为一谈，不外推为跨文化普遍结论。来源链接
- *Robots in the Workplace: a Threat to—or Opportunity for—Meaningful Work?*：用于说明机器人化与有意义工作是需要共同体讨论的规范性问题，不把自动化写成解放或剥夺的必然结果。来源链接
- *Exploring Large Language Models to Facilitate Variable Autonomy for Human-Robot Teaming*：用于说明自治可以作为协作变量调节，不据此断言安全性或责任归属已经得到证明。来源链接
- *Education and Human Development: Embodied AI and the Educational Turn – From Cognition to Situated Presence*：用于说明具身 AI 与教育、在场和学习生态相关，但不据此断言教育效果。来源链接
- *Designing AI Systems that Augment Human Performed vs. Demonstrated Critical Thinking*：用于提醒完成任务的表现不必然等于人的批判性思维已经形成，不把它写成 AI 必然削弱批判性思维。来源链接
- *Keeping an Eye on AI: A Framework for Effective Human Oversight of AI Systems*：用于说明形式上的“人在回路中”不足以构成有意义监督，不量化具体制度效果。来源链接
- *Governance of superintelligence*：用于说明存在面向假设性未来的治理讨论，不证明超级智能已经存在、必然出现或有时间表。来源链接
- *Global catastrophic risk*：用于提供假设性风险术语背景，不作为现实风险事实来源。来源链接