第十章 验证机器生成的知识：从漂亮答案到可检查的主张

开篇：一段让人几乎点头的答案

你让 AI 解释一个陌生的学习现象。它给出一个新概念，补上几条引用，还用流畅的因果链把许多现象串在一起。读到最后，你几乎要点头。可是，当你追问三个问题——它凭什么成立？别人能不能沿着同样的步骤重走一遍？什么情况会让它失败？——你发现自己和它都只能继续生成更顺的句子。

这正是验证机器生成内容的起点：漂亮的表达不是已经成立的知识。生成能力只说明系统提出了一个表达，不自动说明它有真实来源、推导没有跳步、概念前后一致、依据足够，或结论能在新情境中成立。新颖性可以提高研究价值，却不会自动提高可信度；它通常意味着需要承担更多核验工作。

前一章把人机协作中的职责分开：机器可以扩展候选、整理材料、提出反例或模拟方案，人要拆分主张、规定检查标准、判断边界并承担行动后果。本章把这条分工变成一条可照做的路径。机器首先是主张的生成者，而不是主张的裁判。

本章要解决什么问题

面对一段机器生成的答案，你需要知道：怎样把整段话拆成可以检查的主张；怎样分别检查来源、推导、独立性、反例和现实后果；什么时候只把它当作候选，什么时候可以在限定条件下采用；看不懂机器内部机制时怎样既不盲信也不直接否定；怎样把暂缓、拒绝和继续研究写成可恢复的判断。

本章提供的是工作模型和行动建议，不是任何领域的统一阈值。下文的例子用于说明动作，不代表真实研究结果；读者仍需根据对象、场景、风险和可用资料重新检查。

一、先拆主张，不要先评价整段答案

一段输出通常不是一个知识单位。它可能同时包含术语定义、观察事实、相关关系、因果解释、预测、适用范围和行动建议。把整段文字整体接受或整体拒绝，会让你无法知道究竟是哪一部分出了问题。

先把答案改写成一条条主张。每条主张至少问清楚：它具体断言什么；属于定义、事实、因果解释、预测、假设还是建议；对象和条件是什么；依据在哪里；什么会使它失败；目前能走到哪一步；下一步由谁完成。

例如，AI 说“新概念 X 能解释学习迁移”。不能直接问“这句话听起来对不对”，而应拆成：X 的定义是什么？它与已有概念哪里不同？它独特地预测了什么？这些预测不是事后解释吗？在什么条件下会失效？如果这些问题没有清楚答案，X 可

能只是一个有吸引力的标签。

二、第一层：这条主张从哪里来

来源追踪的最低问题不是“有没有引用”，而是“引用是否真的支持这条具体主张”。可以把每条主张放进四列记录：主张、原始来源、对应原文、适用条件。检查对象应包括同一对象、同一结果、同一范围，以及样本、测量、时间、假设和例外。

继续使用开头的场景：AI 给你一条链接，点开后发现原文讨论的是另一种对象，或者只支持“可能相关”，却被答案改写成“已经证明”。这时链接的存在没有拯救主张。失效链接、二手摘要、混合来源和脱离条件的引文，都只能让主张停在待追踪状态。

让来源链可以检查，是发现错误的入口，不是正确性的证明。即使每句话都有链接，仍要检查推导是否跳步、验证者是否独立，以及结论是否在目标环境中有效。有来源的误读仍然是误读；找不到来源也不能单独证明主张为假。

三、第二层：别人能不能重走一遍

“能重做”有不同程度：按照原来的代码、数据和配置重新出现结果；依据公开定义和步骤重建推导；由另一组人或另一套工具独立复核；在新数据、新样本或目标环境中获得外部重复支持。前两层主要检查跳步和操作错误，后两层才触及偶然

条件、共同偏差和现实适用性。

能重现同一个程序的输出，不等于这个程序描述了现实；不同团队得到同一个结果，也可能共同使用了有偏差的数据或不恰当的指标。对于数学、程序或模型输出，至少要留下定义、初始假设、中间步骤、输入数据、版本和随机性、运行环境、失败尝试、舍入或筛选规则，以及别人能够独立重做的最小例子。

如果 AI 给出一段推导，你按它的步骤确实能算出同一个数字，这只说明路径可以重建。若换一组真实数据就失效，现实有效性仍没有得到支持。重建路径解决的是“有没有跳步”，不是“结论能否用于现实”。

四、第三层：别让生成器给自己盖章

把同一段答案再贴回同一个模型，问“请检查你是否正确”，可能发现表面矛盾，却不能充分处理共享数据、提示、假设和评价标准造成的共同错误。另一个窗口里的同一模型，也不因此变成独立验证者。

更有意义的独立检查，应至少改变一个关键条件：验证者、数据切分、实现路径、测量方法、实验地点或理论框架。改变的不是界面，而是可能产生错误的路径。另一个人可以遮住结论，按预先写好的指标分析新数据，或使用不同实现方式检查预测是否仍出现。这也不保证结论正确，但能减少把同一个错

误重复一遍的风险。

机器参与“生成—实验—独立复核”的链条，可以作为具体研究设计中的候选方向；具体案例不能自动推广为所有机器假设都能通过验证。独立不是多问一次同样的问题，而是让关键检查条件真正发生变化。

五、第四层：专家、实验与现实反馈

专家审查的价值，是把领域约束带进来，而不是替机器答案盖章。专家可以检查定义是否进入正确的问题空间、测量是否合理、推导是否漏掉关键变量、实验能否区分竞争解释，以及结论有没有越过适用范围。专家也可能共享偏见，或只检查自己熟悉的部分，所以应保留理由、条件、分歧和未解决问题。

验证层级要与后果相称：低风险的定义改写，回到可靠原文可能已经足够；可计算的结论，可以先由不同的人独立重算；涉及治疗、工程安全、公共决策、他人权益或不可逆行动的主张，不能只依靠机器自评或一次重算，通常还需要领域专家、实验、制度审查或分阶段现实反馈。

现实测试也不是“用了就知道”。测试前应写下成功指标、负面结果、样本或场景、对照、停止条件、异常处置和责任人。高代价行动应先在模拟、沙盒或低风险样本中获取反馈，避免把未经审查的探索成本直接转嫁给现实。

评价标准也可能反过来塑造被评价对象。若只奖励引用数

量，系统可能堆出无关文献；只奖励确定答案，系统可能减少诚实的不确定性；只奖励基准分数，系统可能学习题型而不是可靠推理。因此，一个分数不能独自代表知识质量，还要看来源对应、校准、反例表现、跨情境稳健性和失败披露。

六、找一个真正能推翻它的反例

确认式检查会问“哪里支持它”，压力测试还要问“它在哪里会失败”。可以寻找边界条件，构造表面相似但机制不同的情形，改变关键变量，寻找竞争解释、负结果、失败案例和异常样本。

开头的 AI 如果生成了一个反例，不要马上宣布它已经反驳自己。一个成立的反例必须满足原命题的前提，并且确实破坏它的结论。偷换对象、改变定义或违反适用条件的例子，只是无关例外。

反例搜索可以扩大压力测试的候选空间，但“生成了反例”不等于主张已经被反驳；“没有找到反例”也不等于主张已经被证明。每次搜索都应记录测试了什么、为什么属于命题范围、结果如何，以及主张是被推翻、缩小适用范围，还是暂时得到更多支持。

七、按风险决定验到哪一层

前面的动作可以合成一条路由，但这不是统一量表，也不

是所有领域都适用的固定分数。它更像一张有缺口的网，而不是只向上累加的楼梯：某一处来源缺失，可能阻断整条链；一次高质量实验也补不回定义混乱。

可以按以下顺序决定下一步：先把主张说清，再找到来源和条件；随后重建关键路径，改变至少一个关键验证条件；再进入专家、实验或现实反馈；最后依据风险和责任链决定是否行动。低风险、可逆、容易核对的内容可以停在候选或可重建层，但必须明确仍是候选。学习风险较高时，学习者至少要独立重建、解释、预测并找反例。现实风险高或行动不可逆时，通常需要独立验证、领域专家、实验或制度化审查。

证据冲突时，不要用平均分掩盖冲突。并列记录不同来源、方法、适用范围和未决问题，必要时暂缓采用。验证强度不能靠相互依赖的重复检查伪装出来。

八、看不懂内部机制时怎么办

“我不理解机器为什么这样说”至少有三种情况：没有可检查的依据；依据存在但超出当前背景；内部表征难以解释但外部行为可测。第一种只能停在候选状态，不能因神秘感获得权威。第二种可以拆分术语、寻找可重建的中间模型、请领域专家解释，并设计小规模测试。第三种可以在狭窄条件下测试预测和失效案例，但要承认自己知道的是“它在什么条件下表现如何”，不是“它为何必然如此”。

黑箱不是免检区，也不是自动否定区。至少要保留输入条件、输出版本、可重复的外部行为、失效案例、不确定性表达、独立评估者和停止规则。对信息来源的信任与陈述的事实正确性不是同一件事。适当的姿态不是永不信任，也不是先验崇拜，而是让信任随可检查的表现和行动风险变化。

九、未来机器发现仍需保持条件式

如果未来机器能够提出人类难以直接理解的模型，验证负担可能从“读懂解释”转向检查定义、预测、推导和现实后果。这只是关于一种可能研究情景的条件式讨论，不是关于 AI 已经达到某种能力的事实判断，也不是技术终局预测。即使这种情景发生，人类仍需决定哪些风险可接受、哪些用途需要授权，以及什么证据足以支持行动；这些问题不能由生成能力自动回答。

十、给主张一个可恢复的处置

验证结果不只有“真”或“假”。可以把处置写成四种状态：

继续研究：主张足够清楚，有可执行的预测或实验，潜在价值值得承担研究成本，但尚未达到采用门槛。

限定采用：证据在明确范围内一致，风险可逆，责任人和停止条件清楚。采用时保留条件、未知、复核日期和退出办法。

暂缓采用：已有一些线索，但来源、推导、独立性或现实反馈

存在关键缺口，且错误代价不低。暂停是防止研究线索变成未经授权的事实。

拒绝当前主张：定义自相矛盾、来源无法对应、路径无法重建、关键预测反复失败，或成立的反例直接破坏核心命题。拒绝的是当前表述和当前依据，不必断言整个研究方向没有价值。

每次决定都要写下缺的是什么、谁来补、何时复核，以及哪种结果会改变决定。这样，否定和暂停才是可恢复的研究状态，而不是让机器下一轮换一种说法逃避原来的失败。

小结：把本章带走

回到开头的场景：你让 AI 给出一段听起来无懈可击的新解释，读的时候几乎要点头，可当你要说清它凭什么成立、别人能不能重走一遍、什么会让它失败时，却答不上来。那时你相信的还不是一条经过验证的结论，而是一段写得很顺的话。

如果只记住一件事，那就是：机器生成的首先是“主张”，不是自动完成的“知识”。把主张一条条拆开，追问它从哪来、能不能重做、有没有真正独立的检查、什么会推翻它，再按风险决定验到哪一层。

现在就挑一条你最近接受过的 AI 说法，把它写成一句可判断的主张；补上来源、适用条件、一个可能的反例，以及什么新信息会让你改变判断。

下一章会继续追问：当来自不同学科的主张被机器连接起来时，怎样说明这种连接是经过结构和机制检验的理解，而不只是词汇相似？

参考文献

Scientific Hypothesis Generation and Validation: Methods, Datasets, and Future Directions：用于说明机器参与科学假设生成与验证可以作为研究框架讨论，但不据此断言机器已经发现人类未知规律。见 来源卡。

Inspectable AI for Science: A Research Object Approach to Generative AI Governance：用于说明让来源链可检查是一种候选设计方向，但不据此断言某种溯源方式必然提高正确性。见 来源卡。

Researcher-Curated knowledge governance for trustworthy scientific AI in the geosciences: the rockGPT approach：用于说明研究者策展与检索过程记录能够把生成陈述连回文献，但不把这一领域线索外推为普遍保证。见 来源卡。

What is reproducibility in artificial intelligence and machine learning research?：用于说明人工智能研究中的可重复性有不同层次，并保留独立重做与现实有效之间的区别。见 来源卡。

Design Principles for Falsifiable, Replicable and Reproducible Empirical ML Research：用于说明可证伪、可复制和可重做可

以作为研究设计方向，但不把候选原则写成统一标准。见来源卡。

Accelerating scientific discovery with Co-Scientist：用于说明生成、实验和独立复核可以在具体科学案例中形成链条，但不把单个案例推广为普遍结论。见 来源卡。

Automated hypothesis validation with agentic sequential falsifications：用于说明反例搜索和序贯证伪可以作为验证入口，但不把生成反例写成已经反驳。见 来源卡。

Evaluating large language models for accuracy incentivizes ...：用于提示评价标准可能反过来影响模型行为；材料范围有限，不据此断言某种评测设计普遍有效。见 来源卡。

Epistemic Trust in Generative AI as an Information Source: Development and Validation of the Trust in AI-Epistemic Scale (TAI-E)：用于区分对信息来源的信任与知识陈述的正确性，不把信任测量当作正确性测量。见 来源卡。