第十二章 如果 AI 能提出更好的方案，人类的主体性体现在哪里?

开篇：最后一个确认按钮

一所学校准备重新安排课程和教师值班。系统根据成绩、出勤、教师可用时间和预计成本排出了一套方案，并把它标成“整体最优”。负责排班的员工当天还有许多工作，没看见完整的计算依据，也没有权限暂停系统，只能在页面上点击“确认”。

这个场景里，AI 也许确实更快、更会比较方案。但“更好”究竟是对谁更好？谁承担了被牺牲的时间、机会或风险？那个点击确认的人真的作出了判断，还是只是替一条已经形成的控制链留下了姓名?

本章不把主体性理解为人类必须亲手完成每一步，也不把责任理解为最后一次签字。我们沿着一条实际的判断路径前进：先问“更好”是对谁、在什么范围内更好；再看哪些判断不能被单一指标吞掉；接着检查授权、信息、能力、权限、参与、监测和复盘是否真实存在；最后按任务条件决定哪些可以交给 AI，哪些需要更强的独立审查。

一、AI 更会算，不等于问题已经被正确提出

AI 擅长在给定目标下搜索、排序、预测和优化。但“提高成绩”“降低成本”“减少风险”只是目标的某一面，并不自动等于完整的公共目的。成绩可能与理解脱钩，成本降低可能把负担转给某些人，安全提升也可能以更强监控和更少申诉机会为代价。

面对一个看起来更好的方案，可以先问四句话：

它改善了谁的什么处境？

它把什么代价转给了谁？

哪些代价即使能换来更高分数，也不能接受？

出现什么结果时，我们必须重新讨论原来的目标？

这不是要求人类天然比 AI 更会设定目标。AI 可以列出目标候选、显示冲突、模拟后果，甚至提出人没有想到的评价维度。问题在于，目标是否正当、谁有权决定、受影响者能否质询，不能从一个优化分数自动推出。关于 AI 自主、价值与责任的伦理讨论可以帮助我们看见问题地图，但不能直接给出唯一价值排序或一份永远不可委托的任务清单。

二、六类判断不能被一个指标吞掉

回到排班场景，“整体最优”至少要经过六类追问。它们不是一套已经验证的量表，而是一条帮助读者避免过早接受单一

答案的思考路径。

1. 目标：究竟要解决什么

是提高平均成绩，还是让更多学生获得稳定的学习时间？是减少管理成本，还是让教师能够持续照顾学生？目标声明应说明对象、时间范围、不可牺牲的条件和重新评估的时点。AI可以帮助比较目标，却不能让“可计算”替代“值得追求”。

2. 价值：哪些代价值得承担

效率、公平、隐私、自由、尊严、照护和可持续性可能互相冲突。把其中一个指标设为最高权重，并不会消除冲突，只会把冲突藏进参数。主体性的表现，是能说明取舍理由，听见受影响者的异议，并承认某些选择仍然具有争议。

3. 风险：谁承担不确定性

风险不只是概率乘以损失。还要问损失由谁承担、是否自愿、是否能撤回、是否有替代方案、受影响者是否知道并能申诉。高风险、不可逆或权利影响明显的决定，应提高独立审查、停止和救济的要求。

在网络安全风险判断的一个探索性线索中，研究者关注AI标签、数值建议、判断修订和事后问责。由于具体实验条件和结果方向尚未核验，这不足以支持关于AI建议会造成锚定的普遍结论。它只提醒我们：形式上的“人看过了”，不足以证

明人作出了独立判断。一个较稳妥的工作方法是先写下自己的初步判断，再查看建议，最后说明哪些地方改变了、为什么改变。

4. 关系承诺：对谁持续负责

排班不是一次性的数字交换。它会影响教师与学生、同事与管理者之间持续的关系。承诺意味着结果不理想时，责任主体不能只说“系统就是这样建议的”，而要回到关系中解释、倾听、调整和修复。

AI 可以提醒、比较、记录或帮助准备沟通稿，但流畅的机器文字不能证明承诺已经被理解，也不能证明受影响者真正被看见。是否告知 AI 参与、是否保留异议机会、是否有人跟进异常，都是需要在具体组织中设计和检查的问题。

5. 公共理由：哪些理由可以向他人说明

公共机构和组织的决定，应能向受影响者说明目标、主要依据、风险、责任角色、申诉途径和纠错方式。这里至少要分开三种责任：

心理归因：人们把功劳或责难归给谁；

组织问责：哪个角色需要报告、整改和接受审查；

规范责任：哪个主体有义务防止、解释和修复伤害。

三者可能重合，也可能分离。人们把责难归给 AI，并不表

示法律或道德责任已经转移；让一个人签字，也不表示他拥有实际控制权。

6. 意义：这个行动在生活中意味着什么

当 AI 给出一套效率很高的学习或工作方案，人仍可能追问：我为什么要追求这个结果？这个过程塑造了我想成为的人吗？我愿意以这种方式对待他人吗？这些是规范和解释问题。现有材料对“意义”的直接经验支持尤其薄弱，因此不能把意义写成人类必然垄断的领域，也不能让准确率替所有人回答这些问题。

三、责任不是最后一次点击

排班系统背后可能有开发者、采购者、部署组织、管理者和操作人员。把全部责任压给最后点击确认的人，容易掩盖真正的控制结构：谁设定了目标，谁选择了数据，谁决定了阈值，谁拥有暂停权，谁能修复后果？

这不是替操作人员自动免除责任，而是要求责任与控制、知识、能力和资源相匹配。关于自动化与责任归因的候选研究提示，自动化程度、用户控制和信息处理可能影响人们如何分配责难；但其样本、任务、测量和因果关系尚未核验，心理上的归因转移不等于规范责任已经转移。

因此，判断“谁负责”时要同时问两件事：谁有能力改变结果？谁有义务防止和修复伤害？如果两者不是同一主体，责任

就应沿着系统生命周期分布，而不能把组织设计问题伪装成个人品德问题。

四、让监督真正能够改变结果

1. “人在环”不等于有意义监督

让一个人坐在系统旁边，最后点一下确认，并不自动构成监督。一个人若看不到必要信息、没有时间理解输出、没有能力提出质询、没有暂停或覆盖权限，也没有升级和救济渠道，那么“最终由人负责”很可能只是责任表演。

有意义的监督至少要检查：

是否能访问理解判断所需的信息；

是否有能力识别适用范围、限制和异常；

是否有足够时间形成独立判断；

是否拥有暂停、覆盖、升级和退出权限；

是否能让受影响者提出异议并获得回应；

是否会在结果出来后监测、复盘和修复。

关于有意义监督的材料明确把形式上的人在环与真实监督区分开来。医疗 AI 的候选材料也提示，在高风险医疗场景中，临床人员在场本身不足以使监督有意义，信息、能力、权限与组织条件同样重要。这个医疗线索不能直接外推到教育、网络

安全或普通办公工具；它的作用是提醒我们，具体领域的责任结构必须分别判断。

2. 用七个问题检查责任是否落地

把责任变成可观察行动，可以沿着七个问题检查排班方案：

授权：谁能设定目标、批准使用、修改条件和停止系统？

信息：操作者能看到数据来源、适用范围、不确定性和替代方案吗？

能力：他是否有足够的领域知识、培训和时间质询结果？

权限：他能暂停、覆盖、升级或退出吗，还是只有签字权？

参与：受到影响的人能理解决定、提出异议并获得申诉或救济吗？

监测：谁持续观察异常、偏差、责任稀释和未预期后果？

复盘：谁根据新信息、失败案例和受影响者反馈修改目标与制度？

这是一条工作模型，不是现成的制度标准。它的价值在于让人们追问：被指定负责的人，是否同时拥有足够的信息、能力、时间、权限和资源？如果长期缺少其中一项，就不能把最后确认当作责任已经落实。

五、按条件决定把什么交给 AI

是否委托 AI，不应由“这是事实任务”或“这是价值任务”这样的固定二分决定。事实选择也可能含有价值，价值判断也可能需要技术知识。更稳妥的做法，是同时检查五个条件：

可验证性：输出能否被独立核对？

可逆性：错误能否低成本撤回？

风险与权利影响：错误会影响健康、自由、尊严、机会或公共资源吗？

目标稳定性：目标是否清楚，是否涉及重大价值冲突？

监督可行性：实际监督者是否有信息、能力、时间和权限介入？

低风险、可逆、容易核对、目标较稳定的搜索、排序、计算、模拟和草稿生成，通常更适合提高委托程度。高风险、不可逆、权利影响显著、价值冲突明显，或受影响者难以退出的决定，则需要更强的独立审查、集体程序、停止权和救济机制。

人机互补的候选框架把重点从“是否协作”转向“如何协作”，但其变量、经验基础、任务范围和评价指标尚未核验。因此，它支持的是任务配置思路，而不是“人机组合必然优于单方决策”的结论。

六、教育中的主体性：不只是交出正确答案

教育中的问题更明显。学习的目的不只是提交一份没有错

误的答案，还包括提出问题、解释推理、判断依据、形成身份和与他人共同工作的能力。生成式 AI 进入教育评估，会触及认识权威、教学关系和制度安排；现有材料只能支持把这些当作设计问题，不能据此断言某个工具必然损害或增强学习者的身份、关系或意义。

教师和学习者可以共同追问：

学习者能否提出自己的问题，而不是只优化系统给出的题目？

能否说明为什么接受、修改或拒绝 AI 建议？

能否区分来源事实、个人推论、价值前提和未知？

能否在没有原始对话的情况下重建核心推理，并迁移到新情境？

能否诚实说明 AI 参与了什么，以及最终解释由谁承担？

当答案会影响他人时，能否说明风险、限制和修复方案？

这不是要求所有学习回到无工具状态，而是让学习者在工具存在时仍能保持判断：知道何时调用、怎样质询、何时拒绝，以及怎样把机器产出转化为自己能够解释和承担的行动。教育主体性也不是孤立个人的英雄主义，它需要教师、同伴、评价制度和学校规则共同提供参与、质询和申诉空间。

七、四个反例：主体性也可能失败

第一，人类保留否决权也可能更偏见。疲劳、利益冲突、

刻板印象或对 AI 的盲目信任，都可能影响判断。因此，“人说了算”不是充分条件，独立判断、理由记录、结果校准和接受审查同样重要。

第二，解释可能增加说服，而不是增加理解。一个带有漂亮解释的建议更容易被采纳，并不代表人更能判断。有关解释、公平和适度依赖的材料提示了这个风险，但研究设计和效应方向尚未核验，不能把“有解释”写成“监督有效”。

第三，多人参与可能造成责任稀释。开发者说“用户最终决定”，用户说“系统这样建议”，管理者说“流程要求自动化”，最后可能没有人真正拥有修复权。多人协作不必然导致无人负责，但必须明确角色、权限、记录、升级和救济。

第四，主体性可能被制度形式化。一张填得很完整的审查表，如果不给审查者时间、信息和停止权，记录的只是责任表演。真正要检查的不是按钮、签名或培训次数，而是人是否真的能够形成判断、改变行动方向并修复后果。

小结：把本章带走

回到开头的排班场景：AI 排出了一套看起来更好的方案，最后让一名工作很满、信息不全的员工点“确认”。这个按钮没有自动说明谁真正作出了判断，也没有说明出了问题谁有能力停下来、谁有能力修复。

如果只记住一句话，那就是：**主体性不等于亲手算完每一**

步，责任也不等于最后签个字；关键在于能否把“对谁更好、代价由谁承担”问清楚，并让授权、信息、能力、权限、参与、监测和复盘真正连成行动。

现在可以做一个小练习：挑一个你最近交给 AI 帮忙的决定，写下三件事——谁会被它影响；如果出错，谁有能力停下来；如果当时没有人能停下来，应补上什么权限、记录或申诉路径。

下一章将继续追问：如果 AI 与机器人更深地进入现实任务，人的角色可能怎样变化？哪些变化值得欢迎，哪些风险需要提前看清？这些仍应放在不同技术能力、制度安排和价值选择的条件下讨论，而不能预先写成确定的未来。

参考文献

Ethics of Artificial Intelligence and Robotics：用于说明自主、价值与责任是需要公开讨论的伦理问题，而不是由工具性绩效自动决定的唯一排序。来源链接

Toward a science of human-AI teaming for decision making: A complementarity framework：用于说明人机协作可以按任务条件组织，但不据此断言人机组合必然优于单方决策。来源链接

Responsibility attributions in AI-assisted decisions：用于提醒自动化、用户控制和信息处理可能与责任归因有关，同时区分

心理归因与规范责任。来源链接

AI-Labelled Numeric Advice and Anchoring in Cybersecurity Risk Decisions: An Exploratory Study of Judgment Revision and Post-Decision Accountability：用于提醒形式上的“人看过了”不足以证明独立判断；网络安全场景的线索不直接外推到其他领域。来源链接

Human Agency and Epistemic Authority Under Generative Artificial Intelligence：用于说明生成式 AI 进入教育评估会触及主体性、认识权威和制度安排。来源链接

Designing meaningful human oversight in AI：用于说明形式上的人在环不能自动代表有意义监督成立。来源链接

Meaningful oversight of medical AI beyond human in the loop：用于说明医疗这一高风险场景中，人员在场还不足以构成有意义监督；不把该领域线索直接外推到其他场景。来源链接

Generative AI and Agency in Education: A Critical Scoping Review and Thematic Analysis：用于提示教育主体性可能包含关系维度，但不据此断言生成式 AI 必然改变身份、关系或意义。来源链接

Fostering Human Agency in Age of AI：用于说明学习者主体性可以成为教育系统的设计与评价问题，但不推断具体工具的效果。来源链接

Explanations, Fairness, and Appropriate Reliance in Human-AI Decision-Making：用于说明解释、公平与适度依赖可以被放在同一问题框架中，但不把解释本身当作监督有效的证明。来源链接